

Arquitetura de Computadores III

Memória Primária e Secundária
Hierarquia de Memória

Prof. Matheus Alcântara Souza

1º sem. 2026





Agenda

Hierarquia de memória

Tecnologias de Memória

Memória primária: DRAM

DMA

Memória secundária

- 1 Hierarquia de memória
- 2 Tecnologias de Memória
- 3 Memória primária: DRAM
- 4 DMA
- 5 Memória secundária



Agenda

- 1 Hierarquia de memória
- 2 Tecnologias de Memória
- 3 Memória primária: DRAM
- 4 DMA
- 5 Memória secundária

Arquitetura de von Neumann


Hierarquia de memória

Tecnologias de Memória

Memória primária: DRAM

DMA

Memória secundária



https://en.wikipedia.org/wiki/Von_Neumann_architecture



John von Neumann

- Entrada e saída:
 - Dispositivos de interface com o usuário (Monitor, teclado, mouse, ...)
 - Dispositivos de armazenamento (HDD, SSD, CD/DVD)
 - Adaptadores de rede

Hierarquia de Memória

Hierarquia de memória
Tecnologias de Memória
Memória primária: DRAM
DMA
Memória secundária

Pequeno e rápido

Alto custo

Registradores

Memórias cache
L1, L2 e L3

Memória primária (principal)

Memória secundária

Chip do processador


DRAM

HD, SSD

Baixo custo


Grande e lento

Visão geral de arquitetura (processador MIPS)



Visão geral de arquitetura (processador MIPS)

Hierarquia de memória
Tecnologias de Memória
Memória primária: DRAM
DMA
Memória secundária





Agenda

Hierarquia de memória

Tecnologias de Memória

Memória primária: DRAM

DMA

Memória secundária

1 Hierarquia de memória

2 Tecnologias de Memória

3 Memória primária: DRAM

4 DMA

5 Memória secundária

- **SRAM (Static RAM)**
 - Latência típica: 0,5ns – 2,5ns
 - Custo típico: \$2000 – \$5000 por GB
- **DRAM (Dynamic RAM)**
 - Latência típica: 50ns – 70ns
 - Custo típico: \$20 – \$75 por GB
- **Disco magnético**
 - Latência típica: 5ms – 20ms
 - Custo típico: \$0,20 – \$2 por GB

PATTERSON, D. and HENNESSY, J.,
Computer Organization and Design
The Interface Hardware/Software.

- **SRAM (Static RAM)**
 - Latência típica: 0,5ns – 2,5ns
 - Custo típico: \$2000 – \$5000 por GB
- **DRAM (Dynamic RAM)**
 - Latência típica: 50ns – 70ns
 - Custo típico: \$20 – \$75 por GB
- **Disco magnético**
 - Latência típica: 5ms – 20ms
 - Custo típico: \$0,20 – \$2 por GB

Memória ideal (objetivo)

- Tempo de acesso de SRAM
- Capacidade e custo/GB de disco

PATTERSON, D. and HENNESSY, J.,
Computer Organization and Design
The Interface Hardware/Software.



Agenda

Hierarquia de memória

Tecnologias de Memória

Memória primária: DRAM

DMA


Memória secundária

- 1 Hierarquia de memória
- 2 Tecnologias de Memória
- 3 Memória primária: DRAM**
- 4 DMA
- 5 Memória secundária


Tecnologia DRAM

Dados armazenados como **carga em um capacitor**

- Um **único transistor** acessa a carga.
- Precisa de **refresh periódico**:
 - leitura do conteúdo e reescrita;
 - realizado por **linha (row)** de DRAM.




PATTERSON, D. and HENNESSY, J.,
Computer Organization and Design
The Interface Hardware/Software.



Organização avançada de DRAM


- Bits organizados em uma **matriz retangular**.
 - Acesso típico lê uma **linha inteira (row)**.
 - **Burst mode**: fornece palavras sucessivas da mesma linha com menor latência.
- **DDR (Double Data Rate)**: transferência na borda de subida e de descida do clock.
- **QDR (Quad Data Rate)**: entradas e saídas DDR separadas.



PATTERSON, D. and HENNESSY, J.,
Computer Organization and Design
The Interface Hardware/Software.

Gerações de DRAM (capacidade e custo)

Ano	Capacidade	\$/GB
1980	64 Kbit	\$1.500.000
1983	256 Kbit	\$500.000
1985	1 Mbit	\$200.000
1989	4 Mbit	\$50.000
1992	16 Mbit	\$15.000
1996	64 Mbit	\$10.000
1998	128 Mbit	\$4.000
2000	256 Mbit	\$1.000
2004	512 Mbit	\$250
2007	1 Gbit	\$50



PATTERSON, D. and HENNESSY, J.,
Computer Organization and Design
The Interface Hardware/Software.

Fatores de desempenho em DRAM

Row buffer:

- Permite ler e fazer refresh de várias palavras em paralelo.

DRAM síncrona:

- Acessos consecutivos em burst sem reenviar cada endereço;
- melhora a largura de banda.


Banking:

- Acesso simultâneo a múltiplos bancos/DRAMs;
- melhora a largura de banda.


PATTERSON, D. and HENNESSY, J.,
Computer Organization and Design
The Interface Hardware/Software.

Aumentando a largura de banda da memória


Hierarquia de memória
Tecnologias de Memória
Memória primária: DRAM
DMA
Memória secundária



a. One-word-wide memory organization



b. Wider memory organization




c. Interleaved memory organization

Considerar:

- Bloco de **4 palavras**
- Palavra de **32 bits** (4 bytes)
- Atrasos no barramento:
 - 1 ciclo de clock para enviar o endereço
 - 15 ciclos para cada acesso à DRAM
 - 1 ciclo para enviar uma palavra de dados

PATTERSON, D. and HENNESSY, J.,
Computer Organization and Design
The Interface Hardware/Software.

Aumentando a largura de banda da memória



a. One-word-wide memory organization

Memória com barramento de 1 palavra


- Penalidade de miss:

$$1 + 4 \times 15 + 4 \times 1 = 65 \text{ ciclos de barramento}$$

- Largura de banda:

$$\frac{16 \text{ bytes}}{65 \text{ ciclos}} \approx 0,25 \text{ B/ciclo}$$

Aumentando a largura de banda da memória



b. Wider memory organization

Memória com barramento de 4 palavras


- Penalidade de miss:

$$1 + 15 + 1 = 17 \text{ ciclos de barramento}$$

- Largura de banda:

$$\frac{16 \text{ bytes}}{17 \text{ ciclos}} \approx 0,94 \text{ B/ciclo}$$

Aumentando a largura de banda da memória



c. Interleaved memory organization

Memória interleaved com 4 bancos

- Penalidade de miss:

$$1 + 15 + 4 \times 1 = 20 \text{ ciclos de barramento}$$


- Largura de banda:

$$\frac{16 \text{ bytes}}{20 \text{ ciclos}} = 0,8 \text{ B/ciclo.}$$

Memória DRAM interleaved

Modelo conceitual

<https://www.youtube.com/c/ComputerScienceLessons>




- Dual Inline Memory Module (**DIMM**) com vários chips. Cada chip fornece **8 bits**.
- Com 8 chips: **data bus = 64 bits** (8 bytes) por canal.
- Mesmos endereços podem ser acessados em paralelo (interleaving).

Dentro de um banco de DRAM

Modelo conceitual

<https://www.youtube.com/c/ComputerScienceLessons>



- Bancos organizados como retângulos (linhas & colunas).
- Exemplo: 16k linhas (endereço 14 bits) e 1k colunas (endereço 10 bits).
- Decodificadores de linha/coluna + Mux/Demux + sense amplifiers.

Taxa de clock, largura de banda e nomes (DDR/DIMM)

Standard	Clock rate (MHz)	M transfers/s	DRAM name	MB/s / DIMM	DIMM name
DDR	133	266	DDR266	2128	PC2100
DDR	150	300	DDR300	2400	PC2400
DDR	200	400	DDR400	3200	PC3200
DDR2	266	533	DDR2-533	4264	PC4300
DDR2	333	667	DDR2-667	5336	PC5300
DDR2	400	800	DDR2-800	6400	PC6400
DDR3	533	1066	DDR3-1066	8528	PC8500
DDR3	666	1333	DDR3-1333	10664	PC10700
DDR3	800	1600	DDR3-1600	12800	PC12800
DDR4	1066–1600	2133–3200	DDR4-3200	17056–25600	PC25600

- Exemplo: Uma DIMM usando SDRAM DDR4-3200
 - taxa de transferência por canal: $8 \times 3200 = 25.600$ MB/s
 - nomenclatura do DIMM por banda: **PC25600**

PATTERSON, D. and HENNESSY, J.,
Computer Organization and Design:
The Interface Hardware/Software

HENNESSY, John L., PATTERSON, David A.,
Computer Architecture: A Quantitative Approach



Agenda

Hierarquia de memória

Tecnologias de Memória

Memória primária: DRAM

DMA

Memória secundária


- 1 Hierarquia de memória
- 2 Tecnologias de Memória
- 3 Memória primária: DRAM
- 4 DMA
- 5 Memória secundária

Direct Memory Access (DMA)

Acesso direto à memória

- Mecanismo que permite ao controlador de dispositivo transferir dados diretamente para/de a memória **sem envolver a CPU**.
- Exemplo: DMA na placa de rede (NIC) transferindo dados entre NIC e memória.
- Ao concluir, o DMA notifica via **interrupção de E/S**.
- Interrupção de E/S:
 - 1 é assíncrona em relação à execução de instruções;
 - 2 deve identificar o dispositivo e pode ter prioridades/urgência diferentes.

Direct Memory Access (DMA)



Direct Memory Access (DMA)

Modelos de E/S

- E/S dirigida por **interrupção**:
 - interrupções indicam ao processador que o dispositivo requer atenção.
- **Polling**:
 - checagem periódica do status do dispositivo.
- **E/S mapeada** em memória (MMIO):
 - parte do espaço de endereçamento de memória é atribuída a dispositivos.
- **E/S mapeada** em portas (PMIO):
 - instruções separadas para escrita e leitura em E/S e memória.

PATTERSON, D. and HENNESSY, J.,
Computer Organization and Design:
The Interface Hardware/Software



Agenda

Hierarquia de memória

Tecnologias de Memória

Memória primária: DRAM

DMA

Memória secundária

1 Hierarquia de memória

2 Tecnologias de Memória

3 Memória primária: DRAM

4 DMA

5 Memória secundária


Armazenamento Flash

Armazenamento semicondutor **não volátil**

- **100× a 1000×** mais rápido que disco
- Menor em tamanho e consumo, mais robusto
- Porém maior custo/GB (entre disco e DRAM)
- Acesso uniforme aos dados (tempo de busca)
- Potencial perda de confiabilidade (em um tempo muito distante)

Sugestão de leitura (extra): <https://storedbits.com/how-does-an-ssd-work/>

Operações em SSD (visão conceitual)




SSD (blocos/páginas)

Operações

- **Reescrita**

SSD não sobrescreve “in-place”; grava nova versão e invalida a antiga.

Operações em SSD (visão conceitual)




SSD (blocos/páginas)

Operações

- **Reescrita**

SSD não sobrescreve “in-place”; grava nova versão e invalida a antiga.

Operações em SSD (visão conceitual)




SSD (blocos/páginas)

Operações

- **Reescrita**
- **Apagamento**
- **Coleta de lixo**

SSD não sobrescreve "in-place"; grava nova versão e invalida a antiga. Depois, a coleta de lixo consolida páginas válidas e apaga blocos para recuperar espaço.

Operações em SSD (visão conceitual)




SSD (blocos/páginas)

Operações


- **Reescrita**
- **Apagamento**
- **Coleta de lixo**

SSD não sobrescreve “in-place”; grava nova versão e invalida a antiga. Depois, a coleta de lixo consolida páginas válidas e apaga blocos para recuperar espaço.

Armazenamento em **disco rígido (HDD)**



(a) HDD aberto (visão interna)



(b) Trilhas, setores e cilindros (esquema)

Resumo

- **Pratos:** substrato tipicamente de **alumínio ou vidro**, com revestimento magnético.
- **Cabeçote:** realiza leitura/escrita e “voa” muito próximo à superfície dos pratos.
- **Braço + atuador:** movem o cabeçote radialmente (tempo de *seek*).

Setores de disco e acesso

Cada setor registra

- ID do setor
- dados (512 bytes; 4096 bytes proposto)
- código de correção de erro (ECC) para ocultar defeitos/erros
- campos de sincronização e gaps

Acesso a um setor envolve

- fila (se houver acessos pendentes)
- seek (mover cabeçote)
- latência rotacional
- transferência de dados
- overhead do controlador

Exemplo de tempo de acesso em disco

Cenário

- Setor de 512 B
- Tempo de seek **médio** de 4ms
- 15.000 rpm
- 100 MB/s de taxa de transferência de dados
- overhead do controlador de 0,2ms

Tempo médio de leitura

$$4 + \frac{1}{2} / \left(\frac{15000}{60} \right) + \frac{512}{100 \text{ MB/s}} + 0,2 \approx 6,2 \text{ ms}$$

Exemplo de tempo de acesso em disco

Cenário

- Setor de 512 B
- Tempo de seek **médio** de 4ms
- 15.000 rpm
- 100 MB/s de taxa de transferência de dados
- overhead do controlador de 0,2ms

Tempo médio de leitura

$$4 + \frac{1}{2} / \left(\frac{15000}{60} \right) + \frac{512}{100 \text{ MB/s}} + 0,2 \approx 6,2 \text{ ms}$$

Obs 1: Se seek médio real for 1ms, a média muda para $\approx 3,2 \text{ ms}$

Exemplo de tempo de acesso em disco

Cenário

- Setor de 512 B
- Tempo de seek **médio** de 4ms
- 15.000 rpm
- 100 MB/s de taxa de transferência de dados
- overhead do controlador de 0,2ms

Tempo médio de leitura


$$4 + \frac{1}{2} / \left(\frac{15000}{60} \right) + \frac{512}{100 \text{ MB/s}} + 0,2 \approx 6,2 \text{ ms}$$

Obs 1: Se seek médio real for 1ms, a média muda para $\approx 3,2 \text{ ms}$

Obs 2: Alguns discos incluem caches e podem fazer prefetch para reduzir o tempo de seek/rotação

RAID: Arranjos Redundantes de Discos de Baixo Custo


Níveis comuns de RAID:



- Ideia: aumentar desempenho (paralelismo) e/ou confiabilidade usando múltiplos discos.
- Paridade:** dado redundante calculado a partir de outros dados, usado para detectar e/ou recuperar erros.
- No contexto de RAID, a paridade é o resultado de uma operação **XOR** entre os blocos de dados, armazenado para permitir a reconstrução de um bloco perdido caso um disco falhe.


PATTERSON, D. and HENNESSY, J.,
Computer Organization and Design:
The Interface Hardware/Software

RAID: Arranjos Redundantes de Discos de Baixo Custo




PATTERSON, D. and HENNESSY, J.,
Computer Organization and Design:
The Interface Hardware/Software

RAID: Arranjos Redundantes de Discos de Baixo Custo



PATTERSON, D. and HENNESSY, J.,
Computer Organization and Design:
The Interface Hardware/Software

RAID: Arranjos Redundantes de Discos de Baixo Custo



PATTERSON, D. and HENNESSY, J.,
Computer Organization and Design:
The Interface Hardware/Software

Prefixos e ordens de grandeza

Exp.	Explícito	Prefixo	Exp.	Explícito	Prefixo
10^{-3}	0.001	milli	10^3	1 000	Kilo
10^{-6}	0.000001	micro	10^6	1 000 000	Mega
10^{-9}	0.000000001	nano	10^9	1 000 000 000	Giga
10^{-12}	0.0000000000001	pico	10^{12}	1 000 000 000 000	Tera
10^{-15}	0.0000000000000001	femto	10^{15}	1 000 000 000 000 000	Peta
10^{-18}	0.0000000000000000001	atto	10^{18}	1 000 000 000 000 000 000	Exa
10^{-21}	0.0000000000000000000001	zepto	10^{21}	1 000 000 000 000 000 000 000	Zetta
10^{-24}	0.000000000000000000000001	yocto	10^{24}	1 000 000 000 000 000 000 000 000	Yotta

Valores em base 2

Kilo =

Mega =

Giga =

Tera =

Prefixos e ordens de grandeza

Exp.	Explícito	Prefixo	Exp.	Explícito	Prefixo
10^{-3}	0.001	milli	10^3	1 000	Kilo
10^{-6}	0.000001	micro	10^6	1 000 000	Mega
10^{-9}	0.000000001	nano	10^9	1 000 000 000	Giga
10^{-12}	0.000000000001	pico	10^{12}	1 000 000 000 000	Tera
10^{-15}	0.000000000000001	femto	10^{15}	1 000 000 000 000 000	Peta
10^{-18}	0.000000000000000001	atto	10^{18}	1 000 000 000 000 000 000	Exa
10^{-21}	0.000000000000000000001	zepto	10^{21}	1 000 000 000 000 000 000 000	Zetta
10^{-24}	0.00000000000000000000001	yocto	10^{24}	1 000 000 000 000 000 000 000 000	Yotta

Valores em base 2

Kilo = 2^{10}

Mega = 2^{20}

Giga = 2^{30}

Tera = 2^{40}

- 1ms, 1 μ s, 1ns
- 1000ps = 1ns

Prefixos e ordens de grandeza

Exp.	Explícito	Prefixo	Exp.	Explícito	Prefixo
10^{-3}	0.001	milli	10^3	1 000	Kilo
10^{-6}	0.000001	micro	10^6	1 000 000	Mega
10^{-9}	0.000000001	nano	10^9	1 000 000 000	Giga
10^{-12}	0.000000000001	pico	10^{12}	1 000 000 000 000	Tera
10^{-15}	0.000000000000001	femto	10^{15}	1 000 000 000 000 000	Peta
10^{-18}	0.000000000000000001	atto	10^{18}	1 000 000 000 000 000 000	Exa
10^{-21}	0.000000000000000000001	zepto	10^{21}	1 000 000 000 000 000 000 000	Zetta
10^{-24}	0.00000000000000000000001	yocto	10^{24}	1 000 000 000 000 000 000 000 000	Yotta

Valores em base 2

Kilo = 2^{10}

Mega = 2^{20}

Giga = 2^{30}

Tera = 2^{40}

- 1ms, 1 μ s, 1ns
- 1000ps = 1ns

- 1kb, 1Mb, 1Gb
- 1kbps, 1kb/s
- 128Mb/s

Prefixos e ordens de grandeza

Exp.	Explícito	Prefixo	Exp.	Explícito	Prefixo
10^{-3}	0.001	milli	10^3	1 000	Kilo
10^{-6}	0.000001	micro	10^6	1 000 000	Mega
10^{-9}	0.000000001	nano	10^9	1 000 000 000	Giga
10^{-12}	0.000000000001	pico	10^{12}	1 000 000 000 000	Tera
10^{-15}	0.000000000000001	femto	10^{15}	1 000 000 000 000 000	Peta
10^{-18}	0.000000000000000001	atto	10^{18}	1 000 000 000 000 000 000	Exa
10^{-21}	0.000000000000000000001	zepto	10^{21}	1 000 000 000 000 000 000 000	Zetta
10^{-24}	0.00000000000000000000001	yocto	10^{24}	1 000 000 000 000 000 000 000 000	Yotta

Valores em base 2

Kilo = 2^{10}

Mega = 2^{20}

Giga = 2^{30}

Tera = 2^{40}

- 1 kb / 1kbps = ?
- $1 \times 1024 / 1 \times 1000 = 1,024s$

Comparação: unidades binárias vs decimais

<https://www.ibm.com/docs/en/storage-insights?topic=overview-units-measurement-storage-data>

Binário			Decimal		
Nome	Símbolo	Valor (base 2)	Nome	Símbolo	Valor (base 10)
kibibyte	KiB	2^{10}	kilobyte	KB	10^3
mebibyte	MiB	2^{20}	megabyte	MB	10^6
gibibyte	GiB	2^{30}	gigabyte	GB	10^9
tebibyte	TiB	2^{40}	terabyte	TB	10^{12}
pebibyte	PiB	2^{50}	petabyte	PB	10^{15}
exbibyte	EiB	2^{60}	hexabyte	EB	10^{18}

Tamanho de palavra (word size)

- 1 byte (1B) = 8 bits (8b).
- Uma palavra pode ter diferentes tamanhos (8b, 10b, 16b, 20b, 28b, 30b, ...).

Word size	Valores	Usando prefixo
8b	$2^8 = 256$	—
10b	$2^{10} = 1024$	1kb
16b	$2^{16} = 65\,536$	64kb
20b	$2^{20} = 1\,048\,576$	1Mb
28b	$2^{28} = 268\,435\,456$	256Mb
30b	$2^{30} = 1\,073\,741\,824$	1Gb